

基于机器学习的 UCI 心脏病数据集 二分类预测研究

Leclerc
SASS

2026 年 7 月

摘要

本文以 UCI 心脏病数据集为研究对象，在完成数据清洗和探索性分析的基础上，构建并比较了六种分类模型。实验结果表明，调参后的逻辑回归在测试集上表现最优 (AUC 0.962, 召回率 92.9%)，出人意料地超越了 XGBoost 等复杂模型。本文从样本量、数据线性结构、过拟合风险等角度分析了这一结果，同时利用 Lasso 回归讨论了特征筛选问题，并给出了逻辑回归的显式表达式，将其系数与 SHAP 特征重要性进行了对比。全部代码已开源至 GitHub。

关键词：心脏病预测；逻辑回归；XGBoost；特征筛选；SHAP

目录

1	引言	3
2	数据	3
3	数据清洗	4
4	探索性分析	4
4.1	数值特征	4
4.2	分类特征	5
5	方法	5
5.1	预处理	5
5.2	模型选择	5
5.3	评估与调参	5

目录	2
6 实验结果	6
6.1 交叉验证（调参前）	6
6.2 超参数调优	6
6.3 特征筛选：Lasso vs 全模型	7
6.4 测试集最终评估	7
6.5 ROC 曲线与混淆矩阵	8
7 讨论：为什么简单模型赢了？	9
8 可解释性分析：LR 系数与 SHAP 的对照	10
8.1 逻辑回归的显式表达式	10
8.2 LR 系数与 SHAP 的对应关系	11
9 结论	14

1 引言

心血管疾病是全球头号死因。世界卫生组织的数据显示，每年约 1790 万人因此丧生，接近全球死亡总数的三分之一。如果能在早期阶段识别高风险患者，死亡率可以大幅降低。问题在于，传统诊断高度依赖医生的个人经验，不仅主观性强，而且在医疗资源匮乏的地区难以推广。

机器学习提供了一条不同的思路：让算法从历史病例中自动学习疾病模式，从而给出客观的风险评估。这项工作由来已久——早在 1989 年 Detrano 等人就尝试用概率模型辅助冠心病诊断 [?]，而近年来 XGBoost、随机森林等方法更是在各类医疗预测任务中屡获佳绩。

本文在 UCI 心脏病数据集上做了一个完整的对比实验：从数据清洗到模型调参，从交叉验证到可解释性分析。全文的组织方式如下：第二节介绍数据，第三节给出清洗过程，第四节报告探索性分析的发现，第五节说明方法和模型选择，第六节呈现实验结果（包括 Lasso 特征筛选），第七节讨论为什么最简单的逻辑回归反而表现最好，第八节利用 SHAP 和 LR 系数做可解释性分析，第九节总结全文。

2 数据

数据来自 UCI Machine Learning Repository 的 Heart Disease 数据集（克利夫兰诊所，1988 年）。303 条记录，每条对应一位患者，包含 13 个临床指标和 1 个诊断结果（AHD，即是否患有心脏病）。这套数据虽然样本不大，但结构清晰、质量好，在 ISLR 等教材中被反复使用，适合作为方法对比的基准。表??列出了全部特征。

表 1: 数据集特征一览

特征	类型	含义	取值
Age	数值	年龄	连续值
Sex	二值	性别	0= 女, 1= 男
ChestPain	分类	胸痛类型	typical / atypical / non-anginal / asymptomatic
RestBP	数值	静息血压 (mm Hg)	连续值
Chol	数值	血清胆固醇 (mg/dl)	连续值
Fbs	二值	空腹血糖 > 120 mg/dl	0/1
RestECG	分类	静息心电图	0 / 1 / 2
MaxHR	数值	最大心率	连续值
ExAng	二值	运动诱发心绞痛	0/1
Oldpeak	数值	ST 段压低幅度	连续值
Slope	分类	ST 段峰值斜率	1 / 2 / 3
Ca	数值	大血管数 (荧光染色)	0-3
Thal	分类	地中海贫血类型	normal / fixed / reversible
AHD	目标	诊断结果	No / Yes

数据集中 164 人未患病, 139 人患病, 比例约为 54:46, 基本均衡。考虑到这一点, 后续建模直接使用原始分布, 不做上采样或下采样。

3 数据清洗

逐列检查后发现数据集没有任何缺失值, 也没有重复记录。这个结果在意料之中——UCI 的这套数据经过多年教学使用, 已经被清理得相当干净。不过, 下面写的预处理代码仍然保留了缺失值填补的逻辑 (数值型用中位数、分类型用众数), 纯粹为了代码的通用性。

数值型特征中的离群点用 IQR 方法做检测——超过 $Q_1 - 1.5 \times \text{IQR}$ 或 $Q_3 + 1.5 \times \text{IQR}$ 的观测值被视为异常。处理方式采用 Winsorization: 不删记录, 而是把超出边界的值拉回到边界上。这种做法比直接删除更保守, 不会损失本就不多的样本量。检测下来, RestBP 和 Chol 的异常值略多一些 (约 5%), Oldpeak 和 MaxHR 则很少。

4 探索性分析

4.1 数值特征

五个连续变量按目标分组后, Oldpeak 的区分度最高——心脏病患者的 ST 段压低幅度中位数约为健康人群的三倍, 两组分布几乎不重叠。MaxHR 也有明显分离: 患者的

最大心率普遍更高。Age 的差异符合直觉（老年人患病率更高），但 RestBP 和 Chol 单独看几乎没有区分能力。数值特征间的 Pearson 相关系数整体不高（绝对值均低于 0.5），不存在严重的多重共线性——这一点对后续的逻辑回归建模是天然的有利条件。

4.2 分类特征

分类特征方面，几个模式值得注意。无症状胸痛（asymptomatic）是最危险的类型，这一组中确诊心脏病的比例超过 80%。Thal 中 reversible（可逆性地中海贫血）的患者几乎全部患病，而 normal 类型则绝大多数健康。男性的患病率明显高于女性，Ca（大血管数量）与患病概率之间也存在单调递增关系。这些在 EDA 阶段浮现的模式，后续会由 SHAP 和 LR 系数交叉验证。

5 方法

5.1 预处理

模型训练的输入经过三步处理。分类/二值变量做独热编码（drop='first' 避免共线性），8 个变量展开为 15 个哑变量；连续变量做 Z-score 标准化，确保 KNN 和 SVM 这类对尺度敏感的算法不受量纲影响；数据按 8:2 比例分层划分，训练集 242 条，测试集 61 条，两个集合中的患病比例保持一致。最终的特征矩阵有 20 列——5 个连续变量加上 15 个哑变量。

5.2 模型选择

实验选择了六个模型，覆盖了几种主流的分类范式：逻辑回归作为线性基准，系数可直接解读；K 近邻作为非参数方法的代表；决策树可解释性强但容易过拟合；随机森林通过 Bagging 集成降方差；支持向量机通过核函数处理非线性边界；XGBoost 则是梯度提升集成方法，在结构化数据竞赛中几乎成了标配。

5.3 评估与调参

评估指标选了五个：准确率、精确率、召回率、F1 分数和 AUC-ROC。其中召回率在医疗场景下特别关键——漏掉一个真正的病人（假阴性）远比误报一个健康人（假阳性）的代价大。调参采用 GridSearchCV，以 AUC 为优化目标，在训练集上做 5 折交叉验证。各模型的搜索空间见表??。

表 2: 各模型超参数搜索范围

模型	搜索空间
Logistic Regression	C: [0.01, 0.1, 1, 10]; penalty: [l1, l2]
KNN	n_neighbors: [3,5,7,9,11]; weights: [uniform, distance]
Decision Tree	max_depth: [3,5,7,10,None]; min_samples_split: [2,5,10]
Random Forest	n_estimators: [100,200]; max_depth: [5,10,None]; min_samples_split: [2,5]
SVM	C: [0.1,1,10]; kernel: [linear, rbf]; gamma: [scale, auto]
XGBoost	n_estimators: [100,200]; max_depth: [3,5,7]; learning_rate: [0.01,0.1]

6 实验结果

6.1 交叉验证（调参前）

在调参之前，先通过 5 折交叉验证评估各模型在默认参数下的表现（表??）。

表 3: 5 折交叉验证结果（默认参数）

模型	平均 AUC	标准差	平均准确率	标准差
Logistic Regression	0.8917	0.0481	0.8263	0.0500
Random Forest	0.8761	0.0384	0.7725	0.0695
SVM	0.8662	0.0470	0.8015	0.0577
XGBoost	0.8525	0.0282	0.7850	0.0313
KNN	0.8488	0.0423	0.7975	0.0303
Decision Tree	0.7885	0.0783	0.7891	0.0774

此时逻辑回归已经以 0.8917 的平均 AUC 领先。决策树的标准差最大（0.0783），训练不稳定性明显。XGBoost 的标准差虽然最小（0.0282），但均值只排第四——它的表现很“稳定地中等”。

6.2 超参数调优

GridSearchCV 找到的最优参数和对应的验证集 AUC 汇总在表??。

表 4: 网格搜索最优参数

模型	最优参数	验证 AUC
Logistic Regression	C=1, penalty=l2	0.8903
Random Forest	max_depth=10, min_samples_split=5, n_estimators=100	0.8899
SVM	C=0.1, kernel=linear	0.8899
XGBoost	learning_rate=0.01, max_depth=5, n_estimators=200	0.8712
KNN	n_neighbors=7, weights=distance	0.8592
Decision Tree	max_depth=10, min_samples_split=10	0.8387

有两个细节值得注意。逻辑回归的最优正则化强度 $C=1$ （中等偏弱），意味着 L2 惩罚不需要太强——如果数据高度非线性，需要很强的正则化来压制过拟合，最优 C 会小得多。更直接的证据来自 SVM：GridSearchCV 自动选择了线性核，RBF 核被淘汰了。SVM 本身有能力拟合复杂边界，但它在反复搜索之后“决定”用直线来划分——这几乎是在明说，数据本身就是近似线性可分的。

6.3 特征筛选：Lasso vs 全模型

同学提出了一个合理的问题：为什么不先做变量筛选，而是直接用全部 20 个特征建模？这里补充一个对比实验。将逻辑回归的惩罚项从 L2 换成 L1（即 Lasso 回归），L1 正则化会自动将不重要的特征系数压缩为零，从而起到特征选择的作用。

在同样的训练集上，Lasso ($C=1$) 将 20 个特征中的 4 个系数压缩到零：Age、Fbs_1、Slope_3 和 RestECG_1 被模型自动剔除。其余 16 个特征保留了下来，系数绝对值靠前的是 Ca_2.0 (1.774)、Ca_1.0 (1.570) 和 ChestPain_nonanginal (-1.375)——与 EDA 阶段的观察一致。Lasso 的 5 折交叉验证 AUC 为 0.8896，与全模型 L2 逻辑回归的 0.8917 几乎持平。

这个结果说明两件事。第一，被 Lasso 剔除的四个特征（Age、空腹血糖、心电图 1 类、ST 斜率 3 类）在这个数据集中确实贡献很小，去掉它们对预测能力几乎没有影响。第二，即使保留全模型，L2 正则化也能有效控制这些弱特征的系数（Age 的系数仅为 -0.010，几乎为零），不会因为冗余变量而严重损害泛化能力。因此，本文选择全模型 L2 逻辑回归作为最终方案，是合理的——它既没有因为保留弱特征而付出明显的性能代价，又避免了人为选择变量可能引入的主观性。

6.4 测试集最终评估

将调优后的模型在保留的测试集（61 条样本）上做最终评估，结果见表??，可视化对比见图??。

表 5: 测试集结果汇总

模型	Accuracy	Precision	Recall	F1	AUC
Logistic Regression	0.8689	0.8125	0.9286	0.8667	0.9621
SVM	0.8361	0.8000	0.8571	0.8276	0.9426
KNN	0.8525	0.8065	0.8929	0.8475	0.9416
Random Forest	0.8525	0.8065	0.8929	0.8475	0.9297
XGBoost	0.7705	0.7333	0.7857	0.7586	0.8593
Decision Tree	0.7049	0.6471	0.7857	0.7097	0.7630




图 1: 六种模型在测试集上的五项指标对比

逻辑回归在全部五项指标上都是第一。AUC 达到 0.962——超过 0.9 通常就被认为是”优秀”级别了。召回率 92.9% 意味着只漏诊了大约 7% 的患者，这个数字在临床筛查中是有实际价值的。相比之下，XGBoost 的准确率只有 77%，召回率 78.6%，决策树更是跌到 70.5%——与它们在大规模竞赛数据集上的表现形成鲜明反差。

6.5 ROC 曲线与混淆矩阵

六条 ROC 曲线放在同一张图里（图??），差距相当直观。逻辑回归的曲线始终在最左上角，在所有假阳性率水平上真阳性率都是最高的。随机森林和 SVM 两条曲线几乎重合，KNN 紧随其后，XGBoost 在多个阈值区间被压制，决策树整条曲线都偏低。




图 2: 六种模型的 ROC 曲线对比

最优模型的混淆矩阵（图??）显示，61 个测试样本中，真阳性 26 例，真阴性 27 例，假阳性 5 例，假阴性仅 3 例。




图 3: 逻辑回归在测试集上的混淆矩阵

7 讨论：为什么简单模型赢了？

这个结果初看有些反直觉。XGBoost 在 Kaggle 竞赛中几乎是结构化数据的默认选择，怎么到了这个数据集上反而不如逻辑回归？其实从几个不同的角度去看，原因并不

复杂。

首先是样本量。XGBoost 的核心是梯度提升——每一轮迭代都要拟合上一轮的残差，这需要充足的样本来支撑。但训练集只有 242 条记录，XGBoost 即便被限制了 `max_depth=5` 和 `learning_rate=0.01`，实际有效参数仍然远超逻辑回归的 21 个系数。242 个样本去估计几百个参数，过拟合的风险远高于欠拟合。反观逻辑回归，242:21 的样本-参数比相当宽裕，每个系数都能得到比较稳定的估计。

其次是数据结构。EDA 阶段其实已经给出了线索——Oldpeak、Thal、Ca 这几个关键特征在两组之间几乎是线性分离的。SVM 调参的结果则提供了更强的证据：GridSearchCV 自动选择了线性核，RBF 核被放弃了。如果连 SVM 这种有能力拟合任意复杂边界的模型在搜索之后都“决定”用直线来划分，那说明数据本身确实没有复杂到需要非线性变换的程度。在本来就近似线性的数据上强行用非线性模型，多出来的自由度只会拟合噪声。

过拟合的具体表现也很典型。XGBoost 的交叉验证 AUC (0.8712) 和测试集 AUC (0.8593) 之间有超过 1 个百分点的差距，而逻辑回归这两个数字几乎一致 (0.8903 vs 0.9621，测试集甚至更高)。CV 高、Test 低、差值明显——这差不多是教科书级别的过拟合标志。决策树的情况更极端：调参后 CV 的 AUC 还有 0.8387，到了测试集直接跌到 0.7630，差了将近 8 个百分点。

最后，从临床使用的角度来考虑。即使 XGBoost 在某个指标上和逻辑回归打平，医生也更可能选择后者。逻辑回归的每个系数可以直接读出含义——某个特征增加一个单位，患病对数几率变化多少——这对临床沟通至关重要。XGBoost 的几百棵树叠加在一起，人类无法直观理解它的判断逻辑，只能依赖 SHAP 这类事后解释工具。在医疗领域，“为什么做出这个诊断”往往和“诊断是否准确”同等重要。

8 可解释性分析：LR 系数与 SHAP 的对照

既然逻辑回归是最优模型，一个很自然的追问是：它的系数长什么样？能不能写出一个显式的预测公式？更进一步，这些系数和 SHAP 给出的特征重要性之间是什么关系？

8.1 逻辑回归的显式表达式

L2 正则化逻辑回归 ($C=1$) 拟合的模型可以写成如下形式。设患病概率为 p ，则对数几率表示为：

$$\ln\left(\frac{p}{1-p}\right) = -1.098 + \sum_{j=1}^{20} \beta_j x_j \quad (1)$$

其中截距为 -1.098 ，20 个系数 β_j 按绝对值从大到小排列在表??中。系数为正表示该特征增加时患病风险上升，为负表示保护效应。

表 6: 逻辑回归 (L2, C=1) 系数, 按绝对值降序排列

特征	系数 β	方向
Ca_2.0	+1.412	风险
Ca_1.0	+1.377	风险
ChestPain_nonanginal	-1.338	保护
ChestPain_typical	-1.266	保护
Ca_3.0	+1.122	风险
Sex_1	+0.975	风险
Thal_normal	-0.859	保护
Slope_2	+0.644	风险
ChestPain_nontypical	-0.636	保护
Thal_reversible	+0.589	风险
ExAng_1	+0.496	风险
MaxHR	-0.409	保护
RestECG_2	+0.354	风险
Oldpeak	+0.348	风险
RestBP	+0.264	风险
Slope_3	-0.199	保护
Chol	+0.148	风险
Fbs_1	-0.113	保护
RestECG_1	-0.104	保护
Age	-0.010	保护

以公式 (??) 为基础, 输入任意一位患者的 20 维特征向量, 就能直接计算出患病概率 $p = 1/(1 + e^{-z})$, 其中 z 为线性组合的结果。这种透明性是随机森林或 XGBoost 难以提供的——后者的预测函数是数百棵树的加权组合, 无法压缩成一个简洁的数学表达式。

8.2 LR 系数与 SHAP 的对应关系

表??的排序和 SHAP 特征重要性 (图??、图??) 放在一起看, 可以发现一些有意思的对齐和差异。




图 4: 基于 SHAP 值的特征重要性排名 (XGBoost 模型)




图 5: SHAP 概要图：横轴为 SHAP 值，颜色表示特征值高低

首先看一致的部分。Ca 相关的三个哑变量在 LR 系数和 SHAP 中全部排在前列，Ca_2.0 的 LR 系数 (+1.412) 是所有特征中绝对值最大的，对应 SHAP 概要图中 Ca_2.0 那一行清晰的正向梯度。Thal_normal 在 LR 中显著为负 (-0.859)，在 SHAP 中同样是最重要的保护性特征之一——概要图中 normal 类型的蓝色点集中在负 SHAP 区域。ChestPain 相关的三个哑变量在两个框架下都排名靠前，且方向一致：相对于基线 asymptomatic（风险最高），typical 和 nonanginal 都是保护因素。

但也存在一些差异。最明显的是 Oldpeak：它在 SHAP 概要图中是影响幅度最大的特征（SHAP 值的极差最大），但在 LR 系数中只排第 14 位（绝对值 0.348）。这个差异恰好反映了两类方法的核心区别。SHAP 衡量的是特征对预测结果的总贡献，其中包含

了 Oldpeak 与其他特征之间的交互效应——比如 Oldpeak 和 Thal 同时异常时的联合风险远大于两者单独之和。逻辑回归作为线性模型，无法自动捕捉这种交互，Oldpeak 的主效应系数因此被低估。类似地，MaxHR 在 LR 中的系数符号为负 (-0.409)，意味着最大心率越高、患病风险越低——这在临床直觉上是反过来的。SHAP 概要图提供了更细致的视角：MaxHR 的 SHAP 值在低值和高值区域都比较分散，它的效应可能不是简单的单调关系，而是存在一个最优区间，而这恰好是线性模型无法表达的部分。

值得注意的是 Age——它在 L2 逻辑回归中的系数仅-0.010，在 Lasso 中直接被压为零。但 SHAP 仍然给了它中等的重要性排名。这可能是因为 Age 通过与其他特征（如 MaxHR、Thal）的交互间接发挥作用，而不是作为一个独立的主效应。这也从侧面说明，SHAP 是一种“忠实于模型内部逻辑”的解释方法，而 LR 系数反映的是模型本身的线性假设——两者衡量的不是完全同一个东西。

9 结论

本文在 UCI 心脏病数据集上完成了一个完整的机器学习对比实验，有几点发现值得总结。

第一，逻辑回归是这个数据集上的最佳模型，调参后 AUC 达到 0.962，召回率 92.9%，漏诊率仅约 7%。第二，模型的选择应当由数据特征驱动，而非算法的新旧或复杂程度。XGBoost 在大规模竞赛数据上固然是王者，但放到 303 条样本、近似线性可分的医疗数据上，它的高容量反而成为负资产——SVM 自动选择线性核、XGBoost 的 CV-Test 差距明显、决策树严重过拟合，这些信号从不同角度指向同一个结论。第三，通过 Lasso 与全模型的对比，发现四个弱特征（Age、Fbs、Slope_3、RestECG_1）对预测贡献极小，Lasso 仅用 16 个特征就达到了几乎相同的 AUC (0.8896 vs 0.8917)，全模型 L2 逻辑回归同样通过正则化有效抑制了这些特征的系数，不会因此损失泛化能力。第四，逻辑回归的显式表达式（式??）提供了一种 XGBoost 或随机森林所不具备的透明性，其系数排序与 SHAP 的结果在大方向上是吻合的——Ca、Thal、ChestPain 在两个框架下都是最重要的预测因子——但在 Oldpeak 和 MaxHR 等特征上存在分歧，这恰好揭示了线性模型和 SHAP（基于树模型）在捕捉交互效应方面的本质差异。

本文的局限也很明显。303 条样本限制了复杂模型的空间，1988 年的数据与现代诊断标准和疾病谱之间存在三十多年的差距。未来可以在更大、更新的数据集上验证这些发现，也可以尝试将最优逻辑回归模型封装为一个轻量级的 Web 应用，让临床医生直接上手试用。

参考文献

- [1] James, G., Witten, D., Hastie, T., & Tibshirani, R. (2013). *An Introduction to Statistical Learning*. Springer.

- [2] Detrano, R., Janosi, A., Steinbrunn, W., et al. (1989). International application of a new probability algorithm for the diagnosis of coronary artery disease. *American Journal of Cardiology*, 64(5), 304–310.
- [3] Lundberg, S. M., & Lee, S. I. (2017). A unified approach to interpreting model predictions. *Advances in NeurIPS*, 30.
- [4] Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. *Proceedings of ACM SIGKDD*, 785–794.
- [5] Pedregosa, F., et al. (2011). Scikit-learn: Machine learning in Python. *JMLR*, 12, 2825–2830.
- [6] Wolpert, D. H., & Macready, W. G. (1997). No free lunch theorems for optimization. *IEEE Trans. Evol. Comput.*, 1(1), 67–82.

附录：代码仓库

本文全部代码可在 GitHub 获取：

<https://github.com/L-RichelieuX/heart-disease-prediction>

notebooks/目录包含 EDA 和建模的 Jupyter Notebook，src/为预处理和评估工具模块，results/figures/存放所有输出图表，report/包含本文的 L^AT_EX 源文件及编译后的 PDF。